


Uso de Modelos Predictivos para la Detección de Anomalías en Signos Vitales en Unidades de Cuidados Intensivos Pediátricos

Daniel Felipe Vargas Ulloa

Asesorado por: Maria del Pilar Villamil Giraldo, Ph.D.



Universidad de Los Andes
Facultad de Ingeniería

Proyecto de grado de Ingeniería de Sistemas y Computación

Bogotá, Colombia
Junio de 2025

Índice general

Abstract	i
Resumen	ii
1. Introducción	1
2. Descripción General	3
2.1. Objetivos Específicos	3
2.2. Antecedentes	4
2.3. Importancia del problema	5
3. Requerimientos y Especificaciones	7
3.1. Requerimientos funcionales	7
3.2. Requerimientos no funcionales	8
3.3. Restricciones	8
4. Desarrollo del diseño	9
4.1. Recolección de información	10
4.2. Alternativas de diseño	12
5. Implementación	14
5.1. Descripción de la implementación	14
5.2. Descripción del modelo	14
5.3. Flujo de datos en la arquitectura propuesta	17
6. Validación	22
6.1. Metodología de validación	22
6.2. Resultados	23
6.2.1. Resultados cuantitativos	24
6.2.2. Resultados cualitativos	28
6.3. Código de validación	31
7. Conclusiones	33
7.1. Discusión	33
7.2. Trabajo futuro	34
7.3. Conclusiones finales	35
8. Bibliografía	35

Abstract

Use of Predictive Models for Anomaly Detection in Vital Signs in Pediatric Intensive Care Units

Daniel Felipe Vargas Ulloa

University of the Andes

Supervised by María del Pilar Villamil Giraldo, Ph.D

The effective monitoring of critically ill pediatric patients in intensive care units (ICUs) is a labor-intensive process that demands meticulous analysis to assess each patient's condition. This work explores the use of machine learning models for predictive analytics to identify early warning signs of clinical deterioration. By integrating physiological data from patient monitoring devices, the proposed system aims to support medical decision-making by generating alerts that indicate potential patient instability. The methodology involves data acquisition, preprocessing, model development, and validation in a clinical setting. This approach highlights the potential of predictive analytics to improve patient outcomes by enabling proactive medical interventions.

Keywords: Predictive analytics, anomaly detection, patient monitoring, machine learning, clinical deterioration, early warning signs, proactive intervention.

Resumen

Uso de Modelos Predictivos para la Detección de Anomalías en Signos Vitales en Unidades de Cuidados Intensivos Pediátricos

Daniel Felipe Vargas Ulloa

Universidad de Los Andes

Asesorado por María del Pilar Villamil Giraldo, Ph.D

El monitoreo efectivo de pacientes pediátricos en estado crítico en unidades de cuidados intensivos (UCIs) es un proceso que requiere una gran carga de trabajo y un análisis meticuloso para evaluar la condición de cada paciente. Este trabajo explora el uso de modelos de aprendizaje automático para la analítica predictiva con el fin de identificar signos de alerta temprana de deterioro clínico. Al integrar datos fisiológicos provenientes de dispositivos de monitoreo de pacientes, el sistema propuesto busca apoyar la toma de decisiones médicas mediante la generación de alertas que indiquen una posible inestabilidad en el estado del paciente. La metodología incluye adquisición y preprocesamiento de datos, desarrollo del modelo y validación en un entorno clínico. Este enfoque resalta el potencial de la analítica predictiva para mejorar los desenlaces clínicos al permitir intervenciones médicas proactivas.

Palabras clave: Analítica predictiva, detección de anomalías, monitoreo de pacientes, aprendizaje automático, deterioro clínico, signos de alerta temprana, intervención proactiva.

1. Introducción

En las Unidades de Cuidados Intensivos Pediátricos (UCIP), los pacientes en estado crítico enfrentan condiciones médicas que requieren una atención especializada y constante. Debido a la gravedad de su situación, estos pacientes experimentan variaciones significativas en sus signos vitales, las cuales pueden no ajustarse a los rangos normales para individuos saludables de su misma edad. Además, la complejidad de sus condiciones exige un monitoreo continuo y un análisis detallado por parte de los profesionales de la salud pediátrica, con el objetivo de estabilizar sus condiciones fisiológicas y optimizar sus posibilidades de recuperación.

Uno de los principales desafíos en la atención de pacientes en la UCIP es la capacidad del personal médico para interpretar con precisión los datos que proporcionan los sistemas de monitoreo, los cuales se encargan de medir diversos signos vitales de cada paciente. Esta dificultad, además, se ve acentuada por la desproporción entre el número de pacientes y el personal disponible, lo que limita el tiempo que se puede dedicar a la observación continua y al análisis detallado de cada caso. En este contexto, los sistemas de monitoreo registran múltiples variables fisiológicas esenciales, como la frecuencia cardíaca, la saturación de oxígeno en sangre y la presión arterial, proporcionando información clave para evaluar el estado del paciente (Areia et al., 2021). No obstante, la gran cantidad de datos generados por cada sistema y la necesidad de comprender cómo estas variables se relacionan entre sí pueden dificultar la identificación temprana de complicaciones, lo cual aumenta el riesgo de que ciertos cambios críticos pasen desapercibidos. Cabe destacar que esta situación es especialmente relevante en pediatría, donde los rangos de normalidad varían fuertemente dependiendo de la edad y la condición clínica de cada paciente (Lazo & Andrade, 2020).

Ante esta dificultad, una solución efectiva debe facilitar una interpretación intuitiva y oportuna de los parámetros críticos que permiten evaluar el estado del paciente en la UCIP. Para ello, se requiere un enfoque que simplifique la integración de la información y que, al mismo tiempo, oriente al equipo clínico hacia una toma de decisiones basada en indicadores claros y de fácil interpretación. Además, esta solución, en su concepción, debe favorecer la detección temprana de variaciones preocupantes en los signos vitales, de modo que los profesionales de la salud puedan actuar con mayor rapidez y precisión para prevenir complicaciones.

Para abordar estos desafíos, este trabajo propone la integración de los datos generados por los sistemas de monitoreo en una plataforma capaz de analizar múltiples señales fisiológicas. Con este propósito, se emplea un enfoque de búsqueda en subespacios (subspace search), el cual permite examinar de forma sistemática la relación entre diferentes pares de variables fisiológicas, identificando combinacio-

nes particularmente relevantes para la detección de cambios críticos en el estado del paciente. Este análisis se realizará utilizando el algoritmo de *Hierarchical Temporal Memory* (HTM), el cual está diseñado para identificar patrones en series de datos y detectar comportamientos inusuales o anómalos a medida que evolucionan con el tiempo. A través de esta metodología, el sistema busca ofrecer una evaluación más contextualizada del estado clínico, superando las limitaciones de los enfoques tradicionales que se basan únicamente en comparar los signos vitales con rangos de normalidad predefinidos. Para validar su efectividad, la solución será desarrollada con el apoyo del Hospital Militar Central de Bogotá, con el fin de demostrar que este acercamiento permite la generación de alertas clínicas tempranas ante posibles eventos adversos, promoviendo así intervenciones más oportunas y proactivas por parte del equipo médico en las Unidades de Cuidados Intensivos Pediátricos.

Los resultados obtenidos muestran que el modelo basado en búsqueda en subespacios ofrece un enfoque prometedor para mejorar el análisis del estado clínico de los pacientes a partir de los datos generados por los sistemas de monitoreo. En particular, se logra una mejora considerable en la interpretabilidad de las alertas generadas, en comparación con los modelos predictivos previamente desarrollados para el Hospital Militar Central. Las alertas emitidas por el nuevo sistema son más dicientes y accionables, permitiendo identificar claramente el origen específico de cada evento detectado. Además, el modelo presenta tanto una alta precisión y sensibilidad en la predicción del estado del paciente como una notable resiliencia frente a la intermitencia o pérdida parcial de señales fisiológicas, lo que refuerza su utilidad en contextos clínicos reales y dinámicos.

2. Descripción General

El objetivo principal de este trabajo es desarrollar un sistema que permita monitorear e interpretar anomalías en los signos vitales de pacientes en la Unidad de Cuidados Intensivos Pediátricos (UCIP), utilizando algoritmos de aprendizaje automático. En este contexto, una anomalía se define como un cambio significativo en los patrones normales de comportamiento fisiológico del paciente, el cual puede representar el inicio de un proceso de deterioro clínico y, por tanto, requiere especial atención.

A partir de la detección de estas anomalías, el sistema busca generar alertas dirigidas al personal médico. A diferencia de las anomalías, que son eventos identificados a nivel de procesamiento de datos, las alertas constituyen indicadores explícitos del estado del paciente, diseñados para informar y apoyar al equipo clínico en la evaluación del riesgo de deterioro. Así, el sistema tiene como propósito no solo identificar posibles eventos críticos antes de que se manifiesten, sino también presentar dicha información de forma comprensible y útil, contribuyendo a una respuesta clínica más rápida y fundamentada dentro del entorno dinámico y demandante de una unidad de cuidados intensivos pediátricos.

2.1. Objetivos Específicos

- Implementar y adaptar el modelo HTM para identificar desviaciones significativas en las señales fisiológicas de pacientes en la UCIP, explorando diferentes subespacios que analicen la relación entre distintos signos vitales. De esta manera, se busca capturar cambios sutiles o inesperados que puedan anticipar un posible deterioro clínico.
- Diseñar y desarrollar una interfaz gráfica de usuario que permita visualizar de manera clara y organizada tanto las anomalías detectadas por el modelo HTM como las alertas clínicas generadas por el sistema. Esta interfaz deberá proporcionar al personal médico herramientas de monitoreo intuitivas que faciliten la interpretación rápida del estado del paciente y apoyen la toma de decisiones clínicas oportunas en el entorno dinámico de cuidados intensivos pediátricos.
- Evaluar la efectividad del sistema en términos de métricas como el *F-score* y la tasa de falsos positivos, complementando esta evaluación con retroalimentación del personal médico. Esta validación se lleva a cabo con el fin de asegurar la utilidad práctica y la aplicabilidad de la herramienta en contextos reales de cuidados intensivos pediátricos.

2.2. Antecedentes

La integración de tecnologías avanzadas en el monitoreo y análisis de datos médicos ha sido un área de creciente interés en la última década. Diversos estudios han demostrado el potencial de las técnicas de análisis de datos y aprendizaje automático para mejorar la gestión de pacientes críticos (Varnosfaderani & Forouzanfar, 2024).

Investigaciones recientes han resaltado la eficacia de los modelos analíticos basados en aprendizaje automático (ML) para la detección de anomalías en los signos vitales. Rush et al. (2018) discuten cómo la aplicación de ML a datos fisiológicos continuamente monitoreados tiene un enorme potencial para mejorar la detección de enfermedades, el apoyo a la toma de decisiones clínicas y la eficiencia en el flujo de trabajo. Además, el estudio señala que la integración de ML con datos de registros médicos puede extraer información de gran utilidad a partir de fuentes de datos actualmente sub utilizadas. No obstante, Rush et al. (2018) advierten que la efectividad del aprendizaje automático está condicionada a la calidad y validez de los datos utilizados. En particular, los datos deficientes pueden llevar a diagnósticos erróneos y a decisiones clínicas incorrectas, subrayando la importancia de garantizar que la información utilizada sea precisa y confiable para evitar posibles errores diagnósticos.

En el contexto de la detección de anomalías en cuidados intensivos, las técnicas de aprendizaje automático no supervisado han demostrado ser altamente eficaces. Un estudio relevante es el de Vargas (2023), donde se desarrolló un modelo basado en el análisis de series temporales de datos médicos para identificar anomalías en signos vitales y generar alertas en tiempo real. Según Vargas (2023), “el modelo ha logrado una tasa de detección superior al 50 % y se centra en anomalías contextuales relacionadas con la evolución de los pacientes” (p. 51). Este trabajo evidencia cómo la aplicación de técnicas avanzadas de análisis de datos puede mejorar significativamente la capacidad de detectar condiciones críticas y alertar al personal médico de manera oportuna.

En síntesis, la evolución en el uso de tecnologías para el análisis de datos médicos y la detección de anomalías ha demostrado resultados prometedores en la mejora de la atención clínica. Los estudios analizados destacan cómo el aprendizaje automático optimiza la identificación de patrones anómalos en signos vitales, fortaleciendo la capacidad de respuesta en entornos críticos. La integración de estas técnicas con sistemas de monitoreo avanzados tiene el potencial de transformar la gestión de pacientes en estado crítico, proporcionando herramientas más precisas y eficaces para respaldar la toma de decisiones clínicas y minimizar errores diagnósticos.

2.3. Importancia del problema

El principal problema abordado en este artículo es la dificultad para monitorear y analizar de manera efectiva los signos vitales de los pacientes en las Unidades de Cuidados Intensivos Pediátricos. Estos pacientes se encuentran en condiciones delicadas, donde cualquier variación en sus signos vitales puede ser indicativa de un deterioro crítico. Además, la rapidez y complejidad de estos cambios hacen que el análisis manual resulte una tarea ardua y, en ocasiones, propensa a errores. Cabe destacar que, en contextos donde la proporción entre médicos y pacientes es altamente desfavorable —como sucede en Colombia y otros países de Latinoamérica—, cada profesional de enfermería atiende en promedio a 5,4 pacientes, mientras que cada auxiliar de enfermería atiende a 2,4 (Arango et al., 2015). Esta desproporción genera una elevada carga asistencial que, a su vez, incrementa el riesgo de errores en la monitorización y la atención, lo que puede resultar en demoras críticas y, en última instancia, en un aumento de las complicaciones.

De hecho, esta elevada carga asistencial está asociada directamente con un incremento en la tasa de mortalidad. Tal como evidenciaron Aiken et al. (2002), cada paciente adicional asignado a una enfermera se vincula a un aumento del 7 % en las muertes durante los primeros treinta días posteriores a la admisión. En consecuencia, es imperativo implementar soluciones que optimicen el monitoreo y la atención en las Unidades de Cuidados Intensivos Pediátricos, garantizando una respuesta rápida ante cualquier señal de deterioro y contribuyendo a la reducción de la mortalidad.

Al comparar estas cifras con las de países no latinoamericanos, se observa que algunas naciones de América del Norte y Europa, con sistemas de salud bien desarrollados y economías que asignan mayores recursos al sector sanitario (OECD, 2024), presentan una proporción enfermera-paciente más favorable. Por ejemplo, en Canadá, un análisis realizado por Ariste et al. (2019) calcula que la proporción promedio enfermera-paciente es de aproximadamente 1:4 en hospitales generales. Además, según el Ministerio de Salud de la provincia de Columbia Británica (2024), las Unidades de Cuidados Intensivos (UCI) mantienen una proporción de 1:1, es decir, una enfermera por paciente las 24 horas del día. De manera similar, en el Reino Unido, las UCI suelen operar con una proporción de 1:1, mientras que en Alemania, la proporción promedio es de 1:2,5 durante el turno diurno y de 1:3,5 en el turno nocturno (Depasse et al., 1998).

Ante el desafío que representa la elevada carga asistencial y sus consecuencias críticas, se vuelve imperativo explorar nuevas soluciones. En este sentido, se ha evidenciado una tendencia creciente en la ciencia y la ingeniería hacia la aplicación de tecnologías basadas en análisis de datos y aprendizaje automático para mejorar la atención médica (Davenport & Kalakota, 2019). Estas herramientas permiten procesar grandes volúmenes de información en tiempo real, lo que posibilita respuestas más ágiles y precisas ante situaciones críticas en las Unidades de Cuidados Intensivos Pediátricos.

A su vez, resultados recientes en diversas especialidades—como cardiología, neumología y pediatría—respaldados por estudios como el de Karalis (2024), sugieren que la implementación de este tipo de sistemas en el entorno de cuidados intensivos pediátricos podría ofrecer una mejora significativa tanto en la precisión diagnóstica como en la capacidad para predicción temprana de eventos críticos. Karalis describe como el uso de algoritmos de aprendizaje automático ha permitido realizar diagnósticos más certeros y diseñar planes de tratamiento personalizados en pediatría crítica. Asimismo, como lo evidencia Adegboro et al. (2022) en su revisión sistemática sobre el uso de algoritmos de aprendizaje automático para mejorar la atención en cuidados intensivos, cerca del 78 % de los modelos evaluados superaron a los métodos clínicos convencionales, lo cual destaca el notable potencial de estas tecnologías para transformar la atención médica en entornos críticos.

Por otra parte, la aplicación de soluciones tecnológicas en el ámbito de la salud tiene repercusiones que trascienden el entorno clínico. Desde el punto de vista económico, la optimización en la toma de decisiones y la reducción de errores médicos pueden generar un ahorro significativo en los recursos sanitarios. Ambientalmente, la mejora en la eficiencia operativa se traduce en un uso más racional de insumos y una menor generación de desechos asociados a procesos ineficientes. En el plano social, una atención médica más precisa y oportuna mejora la calidad de vida de los pacientes y sus familias, consolidando la confianza en el sistema de salud.

Además, si bien ya se han implementado soluciones tecnológicas en el Hospital Militar de Bogotá, como el uso de dispositivos de monitoreo médico sofisticados, los cuales son capaces de alertar automáticamente al personal médico cuando alguno de los signos vitales del paciente se encuentra fuera del rango normal para su grupo etario (rangos que deben ser ingresados manualmente por una enfermera). No obstante, estos dispositivos presentan limitaciones importantes en el contexto específico de la Unidad de Cuidados Intensivos Pediátricos. La razón principal es que los pacientes en esta unidad ya se encuentran en estado crítico, por lo que es común que uno o más de sus signos vitales estén fuera del rango convencional. Esto genera un dilema operativo: o bien el dispositivo emite constantes alarmas que resultan molestas para los pacientes y el personal médico, o bien obliga a las enfermeras a ajustar continuamente los umbrales de alarma según las consideraciones del especialista, quien debe evaluar qué valores se consideran normales en función de la edad y la condición clínica del paciente. Esta situación demuestra que, aunque la tecnología está presente, no está plenamente adaptada a las necesidades reales del entorno de cuidados intensivos pediátricos.

3. Requerimientos y Especificaciones

El diseño del sistema propuesto requiere una definición clara de los requerimientos necesarios para guiar su desarrollo, implementación y validación. Estos requerimientos se han clasificado en dos categorías: funcionales y no funcionales. Los primeros hacen referencia a las funcionalidades esperadas del sistema, es decir, qué debe hacer, mientras que los segundos abarcan las propiedades de calidad, restricciones metodológicas y criterios de desempeño que debe cumplir la solución.

3.1. Requerimientos funcionales

Los requerimientos funcionales están directamente relacionados con el procesamiento y análisis de los signos vitales de pacientes en la UCIP. Se dividen en requerimientos de entrada y salida, dada la naturaleza de transformación de datos que realiza el sistema:

- **Entrada:** El sistema debe ser capaz de recibir como entrada un conjunto de datos de monitoreo fisiológico previamente registrados. Estos datos deben incluir múltiples signos vitales por paciente, los cuales pueden presentar intermitencia o dejar de ser registrados después de un tiempo, dadas las condiciones dinámicas de atención clínica.
- **Procesamiento:** El sistema debe analizar de forma conjunta las distintas señales fisiológicas, sin necesidad de conocer con anterioridad cuántas ni cuáles están disponibles, y ser capaz de identificar anomalías dentro de su comportamiento. En este contexto, se define una anomalía como una alteración simultánea en dos o más signos vitales respecto a los valores típicos del propio paciente, lo cual puede reflejar un cambio significativo en su condición clínica. Es importante destacar que un paciente puede entrar en un estado anómalo tanto por un deterioro como por una mejora repentina de su estado clínico, ya que ambas situaciones representan un cambio brusco en las mediciones de los signos vitales. La solución propuesta debe ser capaz de distinguir entre estos dos casos, utilizando como referencia los rangos de normalidad esperados para el paciente según su edad.
- **Salida:** El sistema debe generar alertas categorizadas según el nivel de criticidad de las anomalías detectadas y presentar los resultados del análisis mediante gráficos de series temporales, indicadores visualmente el estado del paciente y el origen de las alertas.

3.2. Requerimientos no funcionales

Desde el punto de vista de calidad y desempeño, el sistema debe garantizar alta confiabilidad y disponibilidad, con tiempos de respuesta mínimos ante la detección de eventos críticos. En términos de seguridad y privacidad, el sistema debe cumplir con las normativas de protección de datos y seguridad informática aplicables en el ámbito hospitalario, de tal forma que la información sensible de los pacientes esté protegida contra accesos no autorizados.

Otro aspecto clave es la interoperabilidad y usabilidad. La solución debe integrarse sin inconvenientes con los sistemas de gestión hospitalaria existentes, asegurando la compatibilidad con los dispositivos médicos en uso. De igual forma, la interfaz desarrollada debe ser intuitiva y de fácil aprendizaje, minimizando la curva de adaptación para el personal de salud.

Finalmente, en cuanto a la metodología de desarrollo, la solución debe construirse siguiendo un enfoque iterativo, que facilite iteraciones rápidas y mejoras continuas basadas en la retroalimentación de los profesionales de la salud.

3.3. Restricciones

El desarrollo e implementación del sistema están sujetos a diversas restricciones que deben ser consideradas para garantizar su viabilidad y alineación con el contexto hospitalario.

- **Restricciones de salud y seguridad:** El sistema no debe interferir con la atención directa del paciente ni generar distracciones que puedan comprometer la seguridad del entorno clínico.
- **Restricciones tecnológicas:** La solución debe ser compatible con los dispositivos médicos y sistemas de gestión hospitalaria existentes, evitando la necesidad de reemplazos costosos o complejas integraciones.

Las restricciones aquí planteadas definen los límites dentro de los cuales debe desarrollarse la solución y orientan la selección de tecnologías, metodologías y estrategias de implementación. El cumplimiento de estas consideraciones es fundamental para asegurar la viabilidad y efectividad del sistema en el contexto hospitalario de la UCIP.

4. Desarrollo del diseño

El desarrollo de esta solución se basa en el trabajo previamente desarrollado por Vargas (2023), quien propuso un modelo de tipo *Hierarchical Temporal Memory* (HTM) para la detección de anomalías en los signos vitales de pacientes en Unidades de Cuidados Intensivos Pediátricos (UCIP). Dicho modelo permite analizar múltiples señales médicas de un paciente de forma conjunta, sin requerir una predefinición del número exacto de variables de entrada.

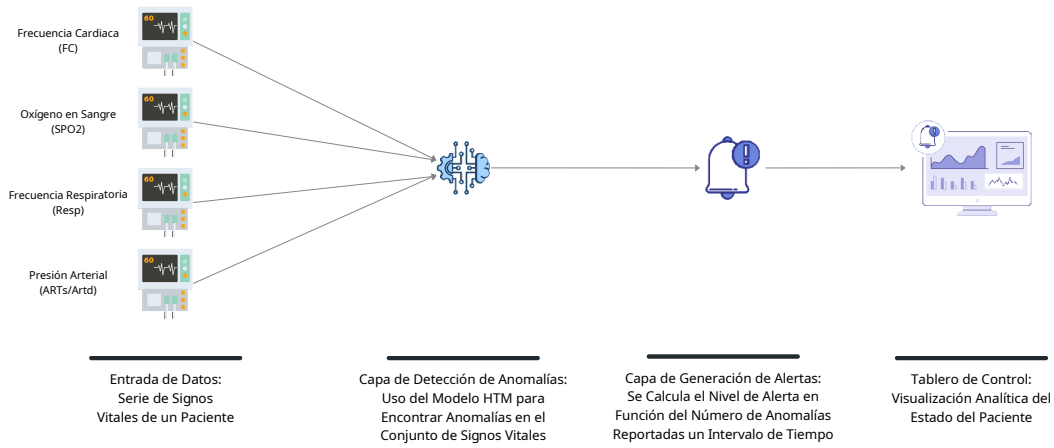


Figura 4.1: Arquitectura del modelo HTM propuesto por Vargas (2023) para la detección de anomalías en signos vitales.

Una de las ventajas más destacables del modelo HTM utilizado por Vargas (2023) es su capacidad de generalización ante una variabilidad en la cantidad de señales fisiológicas disponibles. En entornos reales de la UCIP, no todos los pacientes cuentan con la misma cantidad de dispositivos de monitoreo. Algunos pacientes, debido a su condición crítica, requieren sensores adicionales de naturaleza más intrusiva, mientras que en otros casos, estos dispositivos se reducen gradualmente a medida que su estado clínico mejora. Además, es frecuente que ciertos sensores se desconecten temporalmente durante procedimientos rutinarios como el baño o la movilización del paciente. Frente a estas variaciones, el modelo HTM mantiene su operatividad, pues no requiere una configuración rígida de entradas, adaptándose así a este contexto clínico dinámico.

No obstante, una de las principales limitaciones del modelo propuesto por Vargas (2023) radica en la falta de interpretabilidad de los resultados generados. El sistema es capaz de identificar que una anomalía ha ocurrido, pero no especifica cuál variable o conjunto de variables fisiológicas ha contribuido a dicha detección.

Esta característica reduce el valor explicativo del modelo frente al personal clínico, quienes necesitan comprender con claridad qué parámetros vitales están generando la alerta, de tal forma que puedan identificar de manera precisa los sistemas fisiológicos afectados y ajustar oportunamente sus intervenciones, con el objetivo de estabilizar las condiciones fisiológicas del paciente y maximizar las posibilidades de recuperación. En este contexto, un modelo que permitiera identificar con precisión qué factores fisiológicos están teniendo un mayor impacto en el estado clínico del paciente, tendría un valor significativamente superior para la toma de decisiones médicas fundamentadas (Zhang et al., 2023).

Además, es necesario destacar otra desventaja crítica: el modelo de Vargas (2023) identifica todos los cambios bruscos en las señales fisiológicas como anomalías, sin considerar los rangos de normalidad del paciente. Esta falta de contextualización puede llevar a interpretaciones erróneas. Por ejemplo, incluso cuando un paciente experimenta una mejora clínica y sus parámetros vitales transitan rápidamente desde un estado fuera del rango normal hacia un rango fisiológicamente aceptable, el modelo puede interpretarlo como una anomalía por tratarse de un cambio abrupto. Esta situación puede generar falsas alarmas, provocando interrupciones innecesarias en la atención médica, distracción del personal y, en algunos casos, desgaste en la confianza del equipo clínico hacia el sistema automatizado. En un entorno tan delicado como la UCIP, la precisión de las alertas no solo es deseable, sino crítica.

Por consiguiente, aunque el enfoque propuesto por Vargas (2023) representa un avance significativo en la automatización del análisis de signos vitales, este trabajo busca superar dichas limitaciones mediante un rediseño del sistema de detección, empleando una estrategia basada en detección de anomalías en subespacios (*subspace anomaly detection*). Este enfoque permite asociar cada anomalía detectada con un subconjunto específico de las variables fisiológicas de entrada, brindando así mayor interpretabilidad respecto al origen de las anomalías detectadas. Adicionalmente, se incorporan elementos de contextualización clínica, como la edad del paciente, lo cual permite evitar falsas alarmas cuando se producen cambios en los signos vitales que son esperados en función del contexto clínico del paciente. De este modo, el sistema no solo identifica la ocurrencia de una anomalía, sino que también asocia de forma explícita el conjunto de variables fisiológicas involucradas en dicha anomalía. Esta capacidad resulta fundamental para facilitar la comprensión clínica del evento, mejorar la toma de decisiones médicas y reducir la incidencia de alertas irrelevantes o poco informativas.

4.1. Recolección de información

Para el desarrollo y validación del sistema propuesto, se contó con registros clínicos reales proporcionados por la Unidad de Cuidados Intensivos Pediátricos (UCIP) del Hospital Militar Central de Bogotá. Estos datos fueron suministrados con el propósito de verificar la efectividad del modelo de detección de anomalías propuesto en un entorno clínico real, respetando los lineamientos éticos y de confi-

dencialidad establecidos por la institución.

El conjunto de datos corresponde a pacientes pediátricos entre 8 y 15 años de edad, monitoreados durante períodos continuos que oscilan entre 16 y 24 horas, con una frecuencia de muestreo de un registro por minuto. Esto permite una granularidad suficiente para capturar tanto tendencias lentas como fluctuaciones rápidas en el estado fisiológico del paciente. En total, se recopilieron aproximadamente 136 horas de registros distribuidos en ocho pacientes, lo que otorga una base representativa y sólida para evaluar la eficacia del método propuesto.

La Tabla 4.1 presenta el listado de los pacientes incluidos en el estudio, junto con su edad, diagnóstico médico y la cantidad de horas de monitoreo de signos vitales registradas para cada uno. En total de horas de monitoreo consideradas en el análisis asciende a 122,95 horas.

Id	Edad	Diagnóstico Médico	Horas de monitoreo
Paciente 1	8 años	Tumor Pulmonar	23,03 horas
Paciente 2	10 años	Infarto Cerebral	16,65 horas
Paciente 3	11 años	Tumor Cerebral	16,65 horas
Paciente 4	12 años	Septicemia	16,65 horas
Paciente 5	14 años	Choque séptico refractario	16,65 horas
Paciente 6	15 años	Cetoacidosis diabética	16,65 horas
Paciente 7	15 años	Hipertensión endocraneana	16,65 horas

Cuadro 4.1: Pacientes incluidos en el estudio, diagnóstico y horas de monitoreo registradas.

Para todos los registros de pacientes, se cuenta con registro de todos los siguientes signos vitales, con la excepción del paciente 2, para quien únicamente se dispone de datos de FC, SpO₂ y Resp.

- **FC:** Frecuencia Cardíaca, medida en latidos por minuto.
- **SpO₂:** Saturación de oxígeno en sangre, representada como un valor porcentual.
- **Resp:** Frecuencia Respiratoria, en respiraciones por minuto.
- **ARTs:** Presión Arterial Sistólica, medida en mmHg.
- **ARTd:** Presión Arterial Diastólica, medida en mmHg.

Estos parámetros (“FC”, “SpO₂”, “Resp”, “ARTs” y “ARTd”) constituyen la base principal para evaluar de manera integral el estado hemodinámico y respiratorio del paciente, siendo indispensables para la monitorización en entornos de cuidados intensivos. Si bien se dispone también de registros de la presión arterial media (ARTm), esta magnitud muestra una correlación estadísticamente muy elevada con las presiones sistólica y diastólica, dado que se relaciona directamente con ellas a través de la siguiente fórmula:

$$\text{ART}_m \approx \frac{2 \text{ART}_d + \text{ART}_s}{3}$$

por lo cual su inclusión aportaría información redundante en el modelo. De igual forma, se cuenta con registros de temperatura corporal en la mayoría de los pacientes; no obstante, como menciona Vargas (2023), la temperatura, aunque clínicamente útil en otros contextos, no representa un indicador de alta relevancia para la detección temprana de eventos de deterioro en entornos de cuidados intensivos, donde sus variaciones tienden a ser leves y poco significativas. Por tal motivo, este indicador también fue excluido de las variables de entrada.

Por otro lado, vale la pena resaltar que estos datos recrean varios de los desafíos de la práctica hospitalaria, ya que incluyen lapsos de ausencia ocasionados por desconexiones temporales de los monitores o fallos en la captura de las señales. Dicha heterogeneidad en la disponibilidad y calidad de las mediciones demanda que el sistema sea robusto frente a conjuntos de datos incompletos o intermitentes, tal como ocurre en entornos clínicos.

A continuación, se presenta la tabulación de los signos vitales del paciente 3 a lo largo del tiempo, con el fin de ilustrar gráficamente la presencia de estos periodos de ausencia y la variabilidad en la presencia de ruido en las señales.




Figura 4.2: Evolución temporal de los signos vitales del paciente 3, mostrando periodos de ausencia y ruido en las señales.

4.2. Alternativas de diseño

En su sección de trabajo futuro, Vargas (2023) sugiere como alternativa un esquema en el que el sistema de detección de anomalías se componga de tres modelos predictivos HTM independientes, cada uno alimentado por un par de señales altamente relacionadas: uno con presión sistólica y diastólica, otro con saturación

de oxígeno e índice de perfusión, y un tercero con frecuencia cardíaca y respiratoria. Según Vargas (2023), esta división permitiría mejorar la interpretabilidad, al concentrar cada motor de alarma en una relación estrecha entre señales que provienen de la misma medición o que presentan alta correlación estadística.

No obstante, aunque esta configuración facilita entender qué par de variables está generando cada alerta, el hecho de limitar la búsqueda de anomalías a parejas predefinidas de señales puede empobrecer la calidad global del análisis. Además, restringir la búsqueda de anomalías únicamente a pares de señales ya altamente correlacionadas o procedentes del mismo monitor puede limitar significativamente la capacidad del sistema para detectar patrones clínicos más complejos que afecten diferentes sistemas corporales. En este sentido, Pieroni (2023), al estudiar el uso de distintos modelos de *machine learning* para aplicaciones clínicas, demuestra que considerar un abanico más amplio de parámetros y combinaciones de variables incrementa la capacidad de generalización y el rendimiento predictivo del modelo. Por lo tanto, al analizar un mayor número de interacciones entre signos vitales, se espera capturar patrones de deterioro clínico que de otro modo pasarían desapercibidos.

A partir de este hecho, este trabajo opta por una visión más amplia que expande el concepto de “análisis por pares” a todas las combinaciones posibles de dos señales de entrada (también conocidas como subespacios bidimensionales). En la arquitectura propuesta, cada una de estas combinaciones alimenta de forma independiente un modelo HTM encargado de detectar comportamientos atípicos en el espacio conjunto de la pareja, con el fin de identificar desviaciones en su correlación que puedan indicar un inicio de deterioro fisiológico o un evento adverso. De esta manera, al analizar cada subespacio 2D, el sistema no solo mejora su interpretabilidad, dado que se asocia cada anomalía a una pareja de dos signos vitales, sino que también captura un rango más diverso de anomalías potenciales, reflejando fielmente las complejas interrelaciones que existen entre los distintos signos vitales en la práctica clínica (Pieroni, 2023).

5. Implementación

5.1. Descripción de la implementación

A diferencia de enfoques anteriores que analizan todas las señales médicas como una única entrada conjunta, en este trabajo se propone una estrategia basada en la exploración de relaciones específicas entre variables fisiológicas. En lugar de tratar el conjunto de signos vitales como una entidad monolítica, se opta por aplicar un modelo de detección de anomalías a cada pareja de señales disponible. Es decir, se estudia cada combinación posible de dos señales fisiológicas como un subespacio independiente, lo que permite estudiar la forma en que se relacionan y evolucionan conjuntamente esas dos señales a lo largo del tiempo, capturando interacciones que pueden reflejar cambios fisiológicos relevantes en el estado del paciente.

Concretamente, se analizan las parejas máximas (*max pairs*) formadas a partir del conjunto total de signos vitales disponibles. Este concepto se refiere al número máximo de combinaciones posibles entre dos elementos de un conjunto, considerando todas las posibles parejas únicas sin repetición. Por ejemplo, si se cuentan con n variables fisiológicas, se generan $\frac{n(n-1)}{2}$ subespacios, cada uno correspondiente a una pareja distinta. Cada uno de estos subespacios es procesado individualmente por el modelo de detección de anomalías basado en *Hierarchical Temporal Memory* (HTM), lo que permite identificar patrones anómalos en la evolución conjunta de las dos señales fisiológicas a lo largo del tiempo.

5.2. Descripción del modelo

El modelo propuesto se basa en la arquitectura de *Hierarchical Temporal Memory* (HTM), que es un enfoque inspirado en el funcionamiento del cerebro humano. HTM es particularmente adecuado para el análisis de datos temporales y secuenciales, lo que lo convierte en una opción ideal para el estudio de señales fisiológicas que varían con el tiempo.

El procesamiento de señales fisiológicas continuas plantea diversos desafíos intrínsecos que resulta difícil de manejar con modelos convencionales. Uno de los principales desafíos es la presencia de ruido y artefactos. Esto se debe a que las señales biomédicas frecuentemente se ven contaminadas por interferencias eléctricas, movimientos del paciente o limitaciones de los propios sensores. Esto significa que los datos crudos pueden contener picos o fluctuaciones que no reflejan un cambio real en el estado del paciente, sino meras perturbaciones. HTM aborda esta dificultad gracias a su capacidad para aprender patrones temporales robustos. Al aprender la

estructura temporal normal de la señal, el modelo puede identificar y tolerar cierto nivel de ruido, ya que estos no suelen formar parte de las secuencias coherentes aprendidas, permitiendo que el sistema se enfoque en desviaciones persistentes y significativas del comportamiento normal.

Otro desafío importante es la detección de anomalías sutiles y de evolución lenta. No todas las condiciones críticas se manifiestan como cambios abruptos y evidentes en las señales. Algunas pueden comenzar como desviaciones pequeñas y graduales de la normalidad que, si bien individualmente pueden parecer insignificantes, acumuladas en el tiempo indican un problema emergente. Los métodos que se basan en umbrales fijos o que solo analizan signos vitales aislados pueden pasar por alto estas señales de alerta tempranas. La fortaleza de HTM en este aspecto radica en su capacidad para aprender y predecir secuencias temporales. Al modelar las dependencias temporales en los datos, HTM puede identificar patrones anómalos que se desarrollan a lo largo del tiempo, incluso si las desviaciones en cada punto individual son pequeñas (Ahmad et al., 2017)

Para la implementación práctica de este modelo, se empleó la librería `htm.core`, una librería de código abierto desarrollada en C++ y Python que implementa los algoritmos necesarios basados en la teoría HTM (Otahal et al., 2019). Esta librería proporciona las herramientas necesarias para la codificación, aprendizaje y detección de anomalías en secuencias temporales, facilitando la integración de modelos HTM en aplicaciones de análisis de señales biomédicas.

Respecto a los hiperparámetros utilizados en la configuración de los modelos HTM, se adoptaron los mismos valores reportados por Vargas (2023), quien realizó una búsqueda extensiva de hiperparámetros para optimizar el desempeño en tareas de detección de anomalías en señales fisiológicas. Estos hiperparámetros se aplicaron de forma idéntica en cada uno de los subespacios analizados. No obstante, es importante destacar que la elección de estos valores puede ser ajustada en función de las características específicas de los signos vitales y del contexto clínico en el que se apliquen, permitiendo una personalización adicional del modelo para mejorar su rendimiento en situaciones particulares.

A continuación, se presentan en detalle los hiperparámetros empleados en la implementación, organizados según los componentes principales del modelo HTM: el *Spatial Pooler*, el *Temporal Memory* y los parámetros de detección de anomalías. Las tablas incluyen una breve descripción de cada parámetro para facilitar su interpretación.

Comenzando por el *Spatial Pooler*, este es responsable de transformar la entrada de los dos signos vitales que conforman cada subespacio en una representación binaria, facilitando su procesamiento. Los parámetros utilizados se muestran en la Tabla 5.1.

Parámetro	Valor	Descripción
columnDimensions	2048	Número de 'columnas', unidades que trabajan en paralelo para procesar la entrada.
sp_stimulusThreshold	5	Cuántas señales activas necesita una columna para activarse.
sp_synPermInactiveDec	0.005	Qué tanto se debilita una conexión si no se usa.
sp_synPermActiveInc	0.01	Qué tanto se fortalece una conexión al ser usada.
sp_synPermConnected	0.2	A partir de qué grado de fortalecimiento se considera que la conexión existe de verdad.

Cuadro 5.1: Parámetros del Spatial Pooler (SP).

Como paso siguiente, el *Temporal Memory* aprende secuencias temporales al ver qué señales vienen frecuentemente tras otras, y permite al modelo anticipar patrones futuros. Los parámetros utilizados se muestran en la Tabla 5.2.

Parámetro	Valor	Descripción
tm_cellsPerColumn	16	Cuántas 'células' hay en cada columna para entender el contexto.
tm_activationThreshold	17	Cuántas conexiones activas necesita una célula para activarse.
tm_initialPermanence	0.5	Fuerza inicial de una conexión nueva.
tm_minThreshold	10	Cuántas conexiones en un grupo se necesitan para que empiece a aprender.
tm_maxNewSynapseCount	32	Cuántas conexiones nuevas puede crear cada grupo a la vez.
tm_permanenceIncrement	0.01	Cuánto se fortalece una conexión cuando acierta.
tm_permanenceDecrement	0.1	Cuánto se debilita cuando falla.
tm_predictedSegmentDecrement	0.001	Pequeña reducción si algo se esperaba pero no ocurrió.
tm_maxSegmentsPerCell	128	Máximo de grupos de conexiones por célula.
tm_maxSynapsesPerSegment	128	Máximo de conexiones por grupo.

Cuadro 5.2: Parámetros del Temporal Memory (TM).

Finalmente, los parámetros específicos para la detección de anomalías determinan cómo se evalúan las desviaciones respecto a lo aprendido. Estos parámetros se muestran en la Tabla 5.3.

Parámetro	Valor	Descripción
anom_wait_n	120	Cuántas muestras esperar antes de considerar una anomalía.
anom_window	120	Cuántas muestras usar para calcular la puntuación de anomalía.
threshold	0.1	Valor mínimo para considerar que hay una anomalía.

Cuadro 5.3: Parámetros de la detección de anomalías.

Estos parámetros permiten que el modelo HTM procese eficazmente las señales fisiológicas y detecte anomalías relevantes en cada subespacio definido por las parejas de signos vitales.

5.3. Flujo de datos en la arquitectura propuesta

La figura 5.1 ilustra el flujo de datos en la arquitectura propuesta para emplear modelos HTM en el análisis de señales médicas en subespacios. A continuación se describen con detalle las cuatro secciones que componen el flujo de datos:

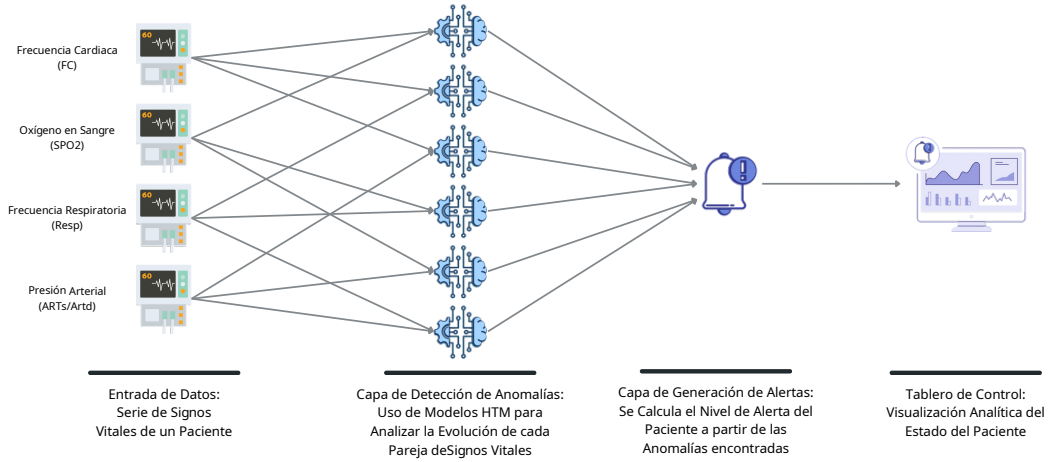


Figura 5.1: Arquitectura de análisis de señales médicas mediante modelos HTM independientes por pareja de signos vitales.

Capa de Entrada de Datos: Procesamiento de Signos Vitales

En la primera etapa de entrada de datos se envían los valores de los diferentes signos vitales procedentes de los dispositivos de monitoreo clínico. Cada par de señales corresponde a un subespacio independiente de análisis. Por ejemplo, (FC, SpO_2) constituye un primer subespacio, $(FC, Resp)$ un segundo, y así sucesivamente hasta cubrir todas las parejas máximas posibles.

En este trabajo, los datos se obtienen como resultado de exportar las lecturas de signos vitales de un paciente, registradas segundo a segundo en un archivo, lo que permite disponer de un registro detallado y continuo para su posterior análisis. Particularmente, la información que se dispone por cada signo vital disponible es:

- Serie temporal de cada señal, con su correspondiente marca de tiempo.
- Identificador del paciente y etiqueta de tipo de señal, de modo que cada registro quede correctamente asociado a su fuente original.
- Edad del paciente, que debe ser ingresada manualmente por las enfermeras al inicio del monitoreo.

Capa de Detección de Anomalías: Modelos HTM por cada subespacio

En esta sección, cada pareja de señales se envía a un modelo HTM independiente. Cada modelo HTM recibe como entrada la serie temporal correspondiente y ejecuta las siguientes operaciones, repitiendo este proceso para cada instante temporal registrado.

1. **Codificación Temporal:** Convierte las lecturas numéricas de ambas señales de entrada en una representación binaria, adecuada para el procesamiento jerárquico de HTM.
2. **Aprendizaje No Supervisado:** el modelo HTM actualiza progresivamente su estructura conforme recibe nuevos vectores de entrada, de modo que aprende los patrones temporales normales de dicha pareja de señales.
3. **Cálculo de Puntuación de Anomalía:** para cada nueva muestra, el modelo HTM calcula un valor escalar entre 0 y 1 que refleja el grado de desviación con respecto al comportamiento aprendido hasta el momento. Se considera que este dato es anómalo si la puntuación supera un umbral predefinido, lo que indica que la pareja de señales presenta un comportamiento inusual en ese instante temporal.

Adicionalmente, al contar con la edad del paciente, cada subespacio tiene la capacidad de ajustar el resultado del modelo en función de los rangos fisiológicos normales para ese grupo etario. Dado que en este enfoque se considera una anomalía como cualquier cambio significativo en la pareja de signos vitales analizada, es posible que el modelo detecte como anómalo un momento en el que el paciente transiciona rápidamente hacia un estado de recuperación, donde todos sus signos vitales se encuentran dentro del rango normal. Esto puede resultar en un falso positivo, ya que el modelo identifica una desviación respecto a la secuencia previa, aunque el nuevo estado sea clínicamente deseable. Para evitar este tipo de falsas alertas, cada subespacio puede decidir ignorar una anomalía si, en el instante considerado, ambos signos vitales de la pareja se encuentran dentro de los valores normales definidos para la edad del paciente. De este modo, se mejora se reduce la generación de alertas innecesarias y se espera mejorar la confiabilidad del sistema.

Por otra parte, ya que definimos una anomalía como una alteración en el comportamiento de dos o más signos vitales, no podemos considerar como anómalo un momento en el que la lectura de alguno de los signos vitales se vea interrumpida. Por lo tanto, si una de las señales de la pareja no está disponible en un instante temporal, el modelo HTM no genera una puntuación de anomalía para ese momento. Esto permite que el sistema pueda manejar situaciones en las que uno o más signos vitales no estén disponibles sin generar alertas erróneas.

Cada modelo HTM envía a la siguiente capa (generación de alertas) la siguiente información:

- *Identificador de la pareja de señales* analizada (por ejemplo, “FC, SpO₂”).
- *Marca de tiempo* que acompaña a la muestra de entrada.
- *Resultado de la puntuación de anomalía*, que es un valor entre 0 y 1, donde 0 indica normalidad y 1 indica una anomalía extrema.
- *Confianza del modelo*, que es un valor entre 0 y 1 que indica la certeza del modelo sobre la puntuación de anomalía calculada.

Capa de Generación de Alertas: Cálculo del Nivel de Alerta del Paciente

La capa de generación de alertas consiste en una composición de los resultados obtenidos en cada subespacio con el fin de determinar el nivel de alerta de un paciente en un instante dado. Para ello, se calcula primero el *nivel de criticidad* de cada subespacio, definido como el producto entre:

- $\delta_i \in \{0, 1\}$: indicador binario que toma valor 1 si el modelo detectó una anomalía en el i -ésimo subespacio, y 0 en caso contrario.
- $c_i \in [0, 1]$: confianza otorgada por el modelo HTM para la puntuación de anomalía en el i -ésimo subespacio.

A partir de estos niveles de criticidad individuales, definimos la criticidad global del paciente en el instante t como la suma de los niveles de criticidad de todos los subespacios que han entregado un resultado válido. Formalmente:

$$C(t) = \sum_{i \in \mathcal{A}(t)} (\delta_i \cdot c_i),$$

donde $\mathcal{A}(t)$ es el conjunto de índices de subespacios activos en el instante t (es decir, aquellos que han entregado un resultado válido y no presentan interrupciones en la lectura de los signos vitales). Sin embargo, puesto que puede ocurrir que algunos subespacios no entreguen respuesta en un instante dado, debido a desconexiones o interrupciones en la lectura de los signos vitales, es necesario normalizar esta suma entre el número de subespacios activos. De esta forma, el *nivel de alerta* del paciente en el instante t se define como:

$$C(t) = \frac{1 + \sum_{i \in \mathcal{A}(t)} (\delta_i \cdot c_i)}{|\mathcal{A}(t)|}$$

Supóngase ahora que en un instante dado sólo se obtienen resultados de 3 de los 6 subespacios ($|\mathcal{A}(t)| = 3$). En este escenario, la suma de los niveles de criticidad parciales tendería a subestimar la condición general del paciente debido a la ausencia de datos en los subespacios faltantes. Por esta razón, mediante la normalización entre $\mathcal{A}(t)$, se evita este sesgo, ya que el nivel de alerta se ajusta al número de subespacios activos en ese instante. Esto permite que el sistema mantenga una evaluación más precisa del estado del paciente, incluso cuando algunos signos vitales no están disponibles.

Tablero de Control: Visualización Analítica del Estado del Paciente

En la última sección, el sistema presenta al personal médico un tablero de control que cumple las siguientes funciones:

- **Monitoreo de Signos Vitales:** Muestra, mediante gráficos de series temporales, la evolución simultánea de los diferentes signos vitales.
- **Criticidad del Paciente:** Visualiza de forma destacada el *Nivel de criticidad Actual* junto con las parejas de señales responsables de dicha puntuación. Esto permite al personal médico identificar rápidamente qué combinaciones de signos vitales están contribuyendo al estado crítico del paciente.
- **Generación de Alertas:** Presenta alertas visuales cuando el nivel de criticidad supera un umbral predefinido, lo que indica que el paciente se encuentra en una situación de riesgo.

Dado que el índice de criticidad calculado por el sistema se encuentra normalizado en un rango entre 0 y 1, es posible establecer umbrales claros y objetivos para la generación de alertas clínicas. En particular, se propone definir tres niveles de alerta: bajo, medio y alto, en función del valor alcanzado por el indicador de criticidad del paciente. Dicho esto, se considera que el paciente se encuentra en un estado de alerta de nivel bajo cuando el índice de criticidad es inferior a 0.3; si el valor se sitúa entre 0.3 y 0.6, se clasifica como alerta de nivel medio; y cuando el índice supera el umbral de 0.6, se clasifica como una alert de nivel alto, indicando una situación de riesgo significativo que requiere atención inmediata. Esta categorización facilita la interpretación rápida del estado del paciente por parte del personal médico y permite priorizar la respuesta clínica de acuerdo con la gravedad detectada por el sistema.

En la Figura 5.2 se presenta la visualización del tablero de control correspondiente al paciente 1 en un momento en el que el sistema considera que el nivel de alerta es bajo. En la parte izquierda del diagrama se observa claramente qué pareja de signos vitales está participando en la generación de la alerta; por ejemplo, la pareja que relaciona la frecuencia cardíaca y frecuencia respiratoria muestra una

criticidad moderada y mayor influencia en la criticidad del paciente, mientras que la pareja de frecuencia cardíaca y saturación de oxígeno presenta una criticidad baja. Esta visualización permite identificar de manera intuitiva no solo qué signos vitales están involucrados en la generación de cada alerta, sino también la severidad asociada a cada combinación, facilitando la priorización de la atención clínica.

En la parte derecha del tablero se encuentra la evolución temporal de los signos vitales seleccionados, presentada en un gráfico que permite al usuario ajustar fácilmente el periodo de tiempo visualizado. Esta funcionalidad es especialmente útil para analizar tendencias recientes o retrospectivas, apoyando la toma de decisiones informadas por parte del personal médico.

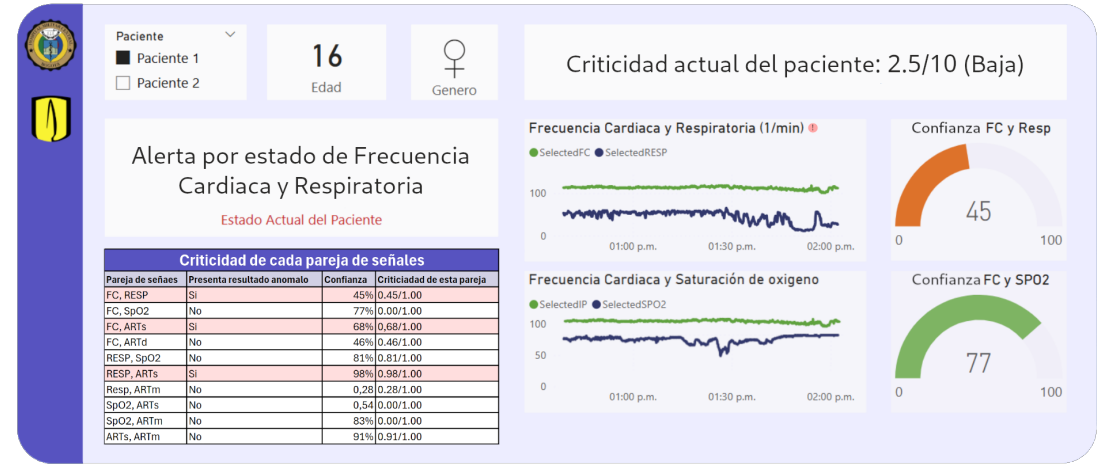


Figura 5.2: Visualización del tablero de control para un instante intermedio del paciente 1 en estado de alerta baja.

Vale la pena destacar que, en el tablero de control, la criticidad del paciente se presenta como un valor en una escala de 0 a 10, en lugar del rango original de 0 a 1 utilizado internamente por el sistema. Esta transformación se realiza simplemente multiplicando el índice de criticidad normalizado por 10. El motivo de esta decisión es facilitar la interpretación por parte del personal médico, ya que una escala de 0 a 10 resulta más intuitiva y familiar para la evaluación rápida de niveles de riesgo, permitiendo identificar de manera inmediata la gravedad del estado del paciente sin necesidad de realizar conversiones mentales adicionales.

De esta manera, el tablero de control proporciona una visión integral y configurable del estado del paciente, resaltando tanto las combinaciones de signos vitales más relevantes para la alerta actual como la evolución de los parámetros fisiológicos a lo largo del tiempo.

6. Validación

6.1. Metodología de validación

Para validar la eficacia del modelo de detección de anomalías en subespacios, se propone una metodología que evalúa sus resultados desde dos dimensiones complementarias: una cualitativa, orientada a la utilidad clínica de las alertas generadas, y otra cuantitativa, enfocada en la relación entre el indicador de criticidad desarrollado y el estado real del paciente medido a través de sus signos vitales.

Primero, a nivel cualitativo se examinan las alertas generadas por el modelo de subespacios para determinar si proporcionan información útil, relevante y accionable para los profesionales de la salud. En este análisis se comparan las alertas de nuestro modelo con las alertas producidas por el modelo previo empleado sobre el mismo paciente en idénticos intervalos de tiempo. Para ello, se revisan las alertas identificadas por cada sistema y se evalúa si las nuevas alertas permiten: (1) anticipar de manera oportuna eventos de deterioro clínico, (2) ofrecer indicaciones claras sobre qué parámetro o combinación de parámetros está fuera de lo esperado y (3) orientar la toma de decisiones médicas de forma más precisa.

En segundo lugar, el análisis cuantitativo busca demostrar que las anomalías reportadas efectivamente coinciden con los momentos en los que el paciente experimenta mayor criticidad fisiológica. Para ello, se utiliza como referencia el número de signos vitales que, en un instante dado, se encuentran fuera de sus rangos normales definidos para la población pediátrica en la UCIP. Este conteo de parámetros alterados se registra segundo a segundo y se considera una medida objetivo para definir el estado del paciente. La Figura 6.1, presenta el resultado de calcular el número de signos vitales fuera de rango en cada instante de tiempo para el paciente 3.

Para realizar esta comparación, el número de signos vitales fuera de rango se clasifica nuevamente en tres categorías de riesgo: alto, medio y bajo. La clasificación se realiza de la siguiente manera: se considera alto riesgo cuando más de dos tercios de los signos vitales monitorizados en ese instante se encuentran fuera de los límites normales; riesgo medio si la proporción de signos vitales alterados está entre un tercio y dos tercios; y bajo riesgo cuando un tercio o menos de los signos vitales presentan valores fuera del rango normal para la edad del paciente. Este criterio es consistente con la metodología utilizada previamente para determinar el nivel de alerta a partir del indicador de criticidad, asegurando así coherencia en la evaluación.




Figura 6.1: Número de signos vitales fuera de rango para el paciente 3.

A partir de esta categorización, se determina si el modelo clasificó correctamente el estado del paciente en los diferentes instantes de tiempo, comparando la categoría de riesgo asignada por el modelo con la obtenida a partir de los signos vitales reales. Esto permite calificar la sensibilidad y precisión de los resultados del modelo, evaluando su capacidad para discriminar entre situaciones de mayor y menor criticidad fisiológica. A continuación, se presentan los rangos de normalidad de los signos vitales para cada grupo etario según la Asociación Española de Pediatría (Fernández, 2020), los cuales se utilizarán como referencia para la validación del modelo.

Signo Vital	0-1 años	1-3 años	4-5 años	6-12 años	13-18 años
ARTs (mmHg)	60–90	78–112	85–114	95–135	100–120
ARTd (mmHg)	30–62	48–78	52–85	58–88	60–80
FC (lpm)	100–160	95–150	80–140	70–120	60–100
Resp (rpm)	30–60	24–40	22–34	18–30	12–16
SpO ₂ (%)	88–100	88–100	88–100	88–100	88–100

Cuadro 6.1: Rangos normales de signos vitales según grupo etario. ARTs: Presión arterial sistólica; ARTd: Presión arterial diastólica; FC: Frecuencia cardíaca; Resp: Frecuencia respiratoria; SpO₂: Saturación de oxígeno.

6.2. Resultados

Los resultados de la validación del modelo de detección de anomalías en subespacios se presentan a continuación, organizados en dos secciones: una que resume los hallazgos cualitativos y otra que detalla los resultados cuantitativos obtenidos.

6.2.1. Resultados cuantitativos

En esta sección se presentan los resultados cuantitativos de la validación del modelo de detección de anomalías en subespacios. El objetivo principal es comparar la clasificación del estado de criticidad del paciente realizada por el indicador propuesto frente a la clasificación basada en el número de signos vitales fuera de rango, considerada como referencia objetiva. Esta comparación permite evaluar la capacidad del modelo para identificar correctamente los periodos de mayor riesgo fisiológico, y reportar alertas que sean coherentes con el estado real del paciente.

Para ilustrar esta comparación, la Figura 6.2 muestra, para el paciente 3, la evolución temporal de cual es el nivel de alerta asignada por el indicador de criticidad y la categoría obtenida a partir del conteo de signos vitales fuera de rango. En el diagrama, cada instante de tiempo se clasifica como riesgo bajo, medio o alto según ambos métodos, permitiendo visualizar la concordancia y las discrepancias entre ellos.




Figura 6.2: Comparación de la clasificación de criticidad para el paciente 3: indicador de criticidad vs. número de signos vitales fuera de rango.

A partir de esta comparación, se observa que el indicador de criticidad propuesto logra identificar correctamente los periodos de alto riesgo fisiológico en la mayoría de los casos, coincidiendo con los momentos donde la mayoría de los signos vitales se encuentran por fuera del rango normal. Además, el modelo muestra una buena capacidad para discriminar entre situaciones de riesgo medio y bajo, reflejando adecuadamente las fluctuaciones en el estado del paciente a lo largo del tiempo.

A continuación, la Tabla 6.2 resume los resultados cuantitativos obtenidos para todos los pacientes incluidos en la validación. En este contexto, la precisión se

refiere a la proporción de instantes en los que el indicador de criticidad predicho por el modelo coincide exactamente con la categoría de riesgo determinada a partir del número de signos vitales fuera de rango. Es decir, mide qué tan confiables son las alertas generadas por el modelo: de todas las veces que el modelo indicó un cierto nivel de riesgo, cuántas veces esa alerta fue correcta. Matemáticamente, la precisión se calcula como:

$$\text{Precisión} = \frac{\text{Número de verdaderos positivos}}{\text{Número de verdaderos positivos} + \text{Número de falsos positivos}}$$

Por otro lado, la sensibilidad (también conocida como *recall*) mide la proporción de instantes en los que el modelo logra identificar correctamente todos los casos reales de una determinada categoría de riesgo. Es decir, de todos los momentos en los que el paciente realmente estuvo en riesgo alto, medio o bajo, cuántos fueron correctamente detectados por el modelo. Matemáticamente, la sensibilidad se calcula como:

$$\text{Sensibilidad} = \frac{\text{Número de verdaderos positivos}}{\text{Número de verdaderos positivos} + \text{Número de falsos negativos}}$$

Cabe destacar que para el cálculo de las métricas cuantitativas presentadas se empleó la librería *sklearn.metrics* de Python. En este proceso, se construyó un arreglo que representa la categoría de riesgo (alto, medio o bajo) en cada instante de tiempo, definida a partir del número de signos vitales fuera del rango normal, el cual se considera como el valor de referencia o “valor de verdad” para la validación. Este arreglo se compara directamente con el arreglo de categorías de riesgo asignadas por el indicador de criticidad generado por el modelo propuesto. De esta manera, se obtienen las métricas de precisión y sensibilidad para cada paciente, permitiendo una evaluación objetiva del rendimiento del modelo.

Id	Precisión	Sensibilidad	F1-Score	F2-Score
Paciente 1	0,31	0,43	0,31	0,36
Paciente 2	0,93	0,95	0,95	0,95
Paciente 3	0,98	0,93	0,95	0,94
Paciente 4	0,34	0,21	0,12	0,14
Paciente 5	0,87	0,87	0,87	0,87
Paciente 6	0,49	0,60	0,51	0,58
Paciente 7	0,73	0,06	0,05	0,04
Resultado Promedio	0,66	0,58	0,54	0,55

Cuadro 6.2: Resultados cuantitativos de la validación del modelo de detección de anomalías en subespacios.

Los resultados muestran que el modelo presenta una precisión promedio del 66 % y una sensibilidad del 58 %, lo que indica que, en general, el indicador de criticidad

logra clasificar correctamente el estado del paciente en la mayoría de los casos. Sin embargo, se observan variaciones significativas entre los diferentes pacientes, con algunos casos como el Paciente 2 y el Paciente 3 alcanzando precisiones superiores al 90 %, mientras que otros como el Paciente 4 y el Paciente 7 presentan resultados más bajos.

Estos hallazgos sugieren que el modelo es más efectivo en algunos pacientes que en otros, lo cual podría deberse a factores como la variabilidad individual en los signos vitales o la presencia de condiciones clínicas específicas que afectan la interpretación de los datos. No obstante, al estudiar estos casos de forma más detallada, se puede observar que estos están siendo influenciados por la suposición de que una baja variabilidad en los signos vitales implica un estado de bajo riesgo. Esta suposición, aunque válida en muchos casos, no se aplica universalmente a todos los pacientes.

Para ilustrar este comportamiento y como esto puede resultar en peores resultados al aplicar esta metodología de validación, la Figura 6.3 muestra la evolución numérica del indicador de criticidad a lo largo del tiempo para el paciente 3. En este caso, se observa cómo el indicador permanece bajo y estable durante los periodos en los que no se detectan anomalías, reflejando correctamente que la condición fisiológica normal del paciente es de bajo riesgo.




Figura 6.3: Evolución temporal del indicador de criticidad para el paciente 3. Se observa que durante los periodos de baja variabilidad y sin anomalías, el indicador permanece bajo, reflejando un estado fisiológico normal.

No obstante, esta suposición no es del todo correcta para pacientes que mantienen todos sus signos vitales consistentemente fuera del rango normal. De acuerdo al proceso de clasificación realizado, estos pacientes deberían clasificarse siempre en alto riesgo. Particularmente, ese es el caso del paciente 7, para el cual el modelo obtuvo un resultado pobre. La Figura 6.4 muestra la comparación entre el indicador de criticidad y la referencia objetiva para este paciente, evidenciando la discrepancia entre ambas clasificaciones. En este caso, el modelo subestima el riesgo al asumir que una baja variabilidad implica un estado de bajo riesgo, a pesar de que todos los signos vitales están fuera de rango.

Comparación de Clasificación de Anomalías en Signos Vitales
 Arriba: Clasificación por número de signos vitales fuera de rango normal
 Abajo: Clasificación por indicador compuesto de anomalía




Figura 6.4: Comparación de la clasificación de criticidad para el paciente 7: indicador de criticidad vs. número de signos vitales fuera de rango. El modelo subestima el riesgo al asumir que una baja variabilidad implica un estado de bajo riesgo, a pesar la mayoría de los signos vitales están fuera de rango.

Estos resultados resaltan la importancia de considerar el contexto clínico del paciente al interpretar los datos de signos vitales y al aplicar el modelos de detección de anomalías con el objetivo de clasificar correctamente su estado de salud. En particular, es fundamental reconocer que la baja variabilidad en los signos vitales no siempre indica un estado de bajo riesgo, especialmente en pacientes con condiciones crónicas o inestables. Por lo tanto, se sugiere que futuras investigaciones consideren incorporar información clínica adicional y ajustar el modelo para mejorar su capacidad de adaptación a diferentes perfiles de pacientes.

Para complementar el análisis cuantitativo, también se calcularon las métricas F1-Score y F2-Score, que proporcionan una medida más equilibrada entre precisión y recall. Estas métricas son especialmente útiles en contextos donde es importante minimizar tanto los falsos positivos como los falsos negativos. Los resultados de estas métricas se presentan en la última dos columnas de la Tabla 6.2, mostrando un rendimiento promedio del modelo en torno al 54 % para F1-Score y 55 % para F2-Score. Estos valores indican que, aunque el modelo logra una clasificación razonablemente precisa, aún existen oportunidades de mejora en su capacidad para identificar correctamente los estados de criticidad del paciente.

Adicionalmente, se realizó este mismo procedimiento de validación para el modelo de detección de anomalías anterior realizado por Vargas (2023), el cual se basa en la identificación de patrones anómalos en el espacio completo de las señales fisiológicas. Los resultados obtenidos para este modelo se presentan en la Tabla

6.3, permitiendo una comparación directa con el modelo basado en subespacios para el mismo conjunto de pacientes.

Id	Precisión	Recall	F1-Score	F2-Score
Paciente 1	0,67	0,59	0,51	0,55
Paciente 2	0,96	0,08	0,09	0,06
Paciente 3	0,99	0,84	0,91	0,86
Paciente 4	0,38	0,33	0,31	0,30
Paciente 5	0,85	0,63	0,72	0,66
Paciente 6	0,36	0,15	0,17	0,15
Paciente 7	0,66	0,63	0,63	0,63
Resultado Promedio	0,70	0,46	0,48	0,46

Cuadro 6.3: Resultados cuantitativos de la validación del modelo anterior basado en el análisis del espacio completo de las señales fisiológicas.

Al comparar directamente los resultados obtenidos para el F1-Score y F2-Score entre ambos modelos, se observa que el modelo basado en subespacios supera en promedio al modelo anterior, alcanzando un F1-Score promedio de 0,54 frente a 0,48 del modelo previo. Esto sugiere que el enfoque de subespacios es más efectivo para identificar correctamente el estado de criticidad del paciente. No obstante, es importante destacar que el modelo anterior presenta una precisión más alta en algunos pacientes, como el Paciente 1 y el Paciente 3, lo que indica que en ciertos casos específicos puede ser más adecuado. Sin embargo, en general, el modelo de subespacios demuestra una mayor robustez y adaptabilidad a diferentes perfiles de pacientes, lo que lo convierte en una opción preferible para la detección de anomalías en el contexto de monitoreo de signos vitales pediátricos.

6.2.2. Resultados cualitativos

Los resultados cualitativos de la validación del modelo de detección de anomalías en subespacios se centran en la utilidad clínica de las alertas generadas y su capacidad para proporcionar información relevante y accionable para los profesionales de la salud. Para evaluar esto, se realizó una revisión exhaustiva de las alertas generadas por el modelo y se compararon con las alertas producidas por el modelo anterior, que se basa en el análisis del espacio completo de las señales fisiológicas.

Para ilustrar estas diferencias, la Figura 6.5 presenta los signos vitales del paciente 5, junto con los puntos marcados con diamantes rojos que indican los momentos en los que el modelo anterior reporta alertas debido a la detección de un estado anómalo. En este caso, aunque se identifican los periodos críticos relevantes (ya que coinciden en su mayoría con momentos con un mayor número de signos vitales por fuera del rango normal), no es posible determinar a partir de la alerta cuáles señales específicas influyeron en su generación. Esta falta de información dificulta que el personal médico pueda reaccionar de manera precisa y dirigida, ya que no se sabe con claridad qué parámetros fisiológicos requieren mayor atención o intervención.




Figura 6.5: Signos vitales del paciente 5 con alertas (diamantes rojos) generadas por el modelo anterior basado en el análisis del espacio completo. La alerta no indica qué señales específicas contribuyeron al estado anómalo.

En contraste, la Figura 6.6 muestra los signos vitales del mismo paciente, pero ahora resaltando las alertas generadas por el modelo de búsqueda en subespacios. En este diagrama, cada alerta está asociada explícitamente a una pareja de señales fisiológicas, correspondiente a aquella combinación que reporta mayor criticidad en ese instante. Esto permite identificar de manera clara cuáles parámetros están contribuyendo más significativamente al estado crítico del paciente. Gracias a esta información adicional, el personal médico puede comprender mejor el origen de la alerta y tomar decisiones más informadas y específicas sobre la intervención clínica necesaria.




Figura 6.6: Signos vitales del paciente 5 con alertas generadas por el modelo de búsqueda en subespacios. Cada alerta está asociada a una pareja de señales, lo que facilita identificar el origen de la criticidad y orientar la respuesta clínica.

Adicionalmente, el modelo propuesto permite evitar la generación de alertas poco relevantes en situaciones donde el paciente presenta todos sus signos vitales dentro del rango normal, gracias a la incorporación explícita de la edad del paciente

en el proceso de detección de anomalías. Esta característica resulta especialmente relevante en el ámbito pediátrico, donde los rangos normales de los signos vitales varían considerablemente según la edad. Al considerar esta variable, el modelo es capaz de filtrar alertas que no aportan información clínica significativa, evitando así notificaciones innecesarias como las que fueron reportadas por el modelo anterior entre las 22:00 y las 24:00 horas del paciente 5, periodo en el cual todos los signos vitales se encontraban dentro de los límites normales para su edad (véase Figura 6.5). En estos casos, el modelo de subespacios no genera alertas superfluas, lo que contribuye a reducir la sobrecarga de alarmas y permite al personal médico enfocar su atención en situaciones realmente críticas.

Para validar este resultado entre todos los pacientes, se realizó un análisis respecto a la generación de falsas alertas, es decir, aquellas alertas que se generan cuando el paciente no presenta signos vitales fuera del rango normal. La Tabla 6.4 resume los resultados de este análisis para cada paciente, indicando el número total de alertas generadas por el modelo de subespacios y cuántas de ellas corresponden a situaciones donde todos los signos vitales están dentro del rango normal.

Id	Instantes con falsas alertas reportadas por el modelo de búsqueda en subespacios	Instantes con falsas alertas reportadas por el modelo original
Paciente 1	91	267
Paciente 2	485	481
Paciente 3	85	408
Paciente 4	15	17
Paciente 5	228	31
Paciente 6	110	271
Paciente 7	52	263
Resultado Total	1066	1738

Cuadro 6.4: Comparación del número de instantes con falsas alertas generadas por el modelo de búsqueda en subespacios y el modelo original para cada paciente.

Los resultados muestran que el modelo de subespacios genera significativamente menos falsas alertas en comparación con el modelo original. En total, se reportaron 1066 instantes con falsas alertas por parte del modelo de subespacios, mientras que el modelo original generó 1738 instantes de falsas alertas. Esto representa una reducción del 38,7% en la cantidad de alertas innecesarias, lo cual es un resultado significativo considerando la importancia de minimizar la sobrecarga de alarmas en entornos clínicos.

En general, los resultados cualitativos indican que el modelo de búsqueda en subespacios no solo mejora la precisión en la detección de anomalías, sino que también proporciona alertas más útiles y relevantes para el personal médico. Al asociar cada alerta a una pareja específica de señales fisiológicas, se facilita la identificación de patrones críticos y se optimiza la respuesta clínica, contribuyendo así a una atención más efectiva y centrada en el paciente. Por otra parte, la reducción

de falsas alertas permite mejorar la confianza del personal médico en el sistema de monitoreo, al disminuir la cantidad de notificaciones irrelevantes que pueden generar distracción o fatiga ante alarmas.

6.3. Código de validación

A continuación se presenta el código utilizado para realizar la validación del modelo de detección de anomalías en subespacios, incluyendo la categorización de los datos y el cálculo de las métricas de precisión, sensibilidad, F1-Score y F2-Score. Este código utiliza las librerías *pandas* y *sklearn.metrics* de Python para procesar los datos y calcular las métricas de validación.

```
1 import pandas as pd
2 from sklearn.metrics import classification_report, f1_score, fbeta_score
3
4 # El DataFrame patient_data contiene, para cada instante de tiempo, la
  → columna 'Normalized Vitals', que representa la cantidad de signos
  → vitales fuera de su rango normal, dividida por el número total de
  → signos vitales disponibles para ese paciente. De esta manera, el
  → valor está normalizado entre 0 y 1, indicando la proporción de
  → signos vitales alterados en cada momento.
5
6 # Por otro lado, el DataFrame indicator_data incluye la columna
  → 'Normalized Indicator', que corresponde al valor del indicador de
  → criticidad en cada instante, normalizado por el número de
  → subespacios disponibles en ese momento. Así, este valor también se
  → encuentra entre 0 y 1 y permite comparar la criticidad detectada por
  → el modelo con la proporción de signos vitales alterados.
7
8 def categorize_vitals_and_indicator(patient_data, indicator_data):
9     """
10     Categoriza los valores normalizados del indicador de criticidad y
    → del número de signos vitales fuera de rango en tres categorías:
    → bajo, medio y alto, según umbrales definidos.
11     """
12     low_th = 0.3
13     high_th = 0.6
14
15     # Categoría para anomalías normalizadas
16     patient_data['True Category'] = pd.cut(
17         patient_data['Normalized Vitals'],
18         bins=[-float('inf'), low_th, high_th, float('inf')],
19         labels=['Low', 'Medium', 'High']
20     )
21
22     # Categoría para el indicador
23     indicator_data['Indicator Category'] = pd.cut(
24         indicator_data['Normalized Indicator'],
```

```

25         bins=[-float('inf'), low_th, high_th, float('inf')],
26         labels=['Low', 'Medium', 'High']
27     )
28
29     # Sincroniza ambos DataFrames
30     comparison_df = pd.DataFrame({
31         'Start Time': indicator_data['Start Time'].values,
32         'End Time': indicator_data['End Time'].values,
33         'True Category': patient_data['True Category'].values,
34         'Indicator Category': indicator_data['Indicator
        ↳ Category'].values
35     })
36
37     return comparison_df
38
39 def calculate_metrics(comparison_df):
40     """
41     Calcula precisión, recall, F1 y F2-score usando sklearn.metrics.
42     """
43     report = classification_report(
44         comparison_df['True Category'],
45         comparison_df['Indicator Category'],
46         output_dict=True,
47         zero_division=0
48     )
49     f1 = f1_score(comparison_df['True Category'],
        ↳ comparison_df['Indicator Category'], average='weighted')
50     f2 = fbeta_score(comparison_df['True Category'],
        ↳ comparison_df['Indicator Category'], beta=2, average='weighted')
51
52     return report['weighted avg']['precision'], report['weighted
        ↳ avg']['recall'], f1, f2
53
54 def count_false_positives(comparison_df)
55     """
56     Cuenta los falsos positivos: instantes donde el indicador predice
        ↳ anomalía pero no hay anomalía real.
57     """
58     return ((comparison_df[indicator_col] != 'Low') &
        ↳ (comparison_df['True Category'] == 'Low')).sum()
59
60 # Calcula las métricas de validación
61 comparison_df = categorize_vitals_and_indicator(patient_data,
        ↳ indicator_data)
62 precision, recall, f1, f2 = calculate_metrics(comparison_df)
63 false_positives = count_false_positives(comparison_df)

```

7. Conclusiones

7.1. Discusión

El presente trabajo ha explorado el uso de modelos de búsqueda en subespacios para el análisis de datos fisiológicos provenientes de monitores médicos, con el objetivo de mejorar la detección de anomalías y la interpretación de alertas clínicas. A través del análisis de un conjunto de datos sintéticos y reales, se ha demostrado que este enfoque no solo es viable, sino que también ofrece ventajas significativas en términos de sensibilidad y especificidad en la identificación de patrones anómalos.

El modelo de búsqueda en subespacios ha mostrado resultados prometedores para mejorar el análisis de pacientes a través de datos provenientes de monitores médicos. Al descomponer el conjunto de señales fisiológicas en parejas de variables, se logró capturar interacciones específicas que no son evidentes cuando se tratan todas las señales de forma conjunta, lo cual permitió detectar patrones anómalos de manera más efectiva. Este enfoque demuestra que la exploración en subespacios puede aportar información clínica relevante y complementar las metodologías tradicionales de monitoreo, favoreciendo una interpretación más detallada del estado de cada paciente y reduciendo el número de falsos positivos en las alertas generadas.

Asimismo, fue posible mejorar considerablemente la interpretabilidad de las alertas reportadas por el modelo anterior, generando resultados accionables para el personal médico. Debido a que cada subespacio está asociado a una pareja de signos vitales concreta, las alertas indican explícitamente qué combinación de variables está presentando un comportamiento anómalo, lo que facilita la toma de decisiones rápidamente orientadas a intervenciones específicas. En consecuencia, el personal de salud puede identificar con mayor claridad las causas subyacentes de cada alerta y priorizar acciones clínicas basadas en la criticidad de cada subespacio, optimizando así la atención al paciente.

Por último, se conservó la resiliencia ante la intermitencia de las señales y la alta precisión y sensibilidad en la predicción del estado del paciente al comparar los resultados con métricas clínicas bien establecidas. Esto sugiere que el modelo no solo es robusto frente a la variabilidad inherente de los datos fisiológicos, sino que también puede integrarse eficazmente en flujos de trabajo clínicos reales, proporcionando un valor añadido significativo en la monitorización continua de pacientes críticos.

7.2. Trabajo futuro

A partir de lo presentado en este trabajo y considerando las limitaciones actuales del enfoque de búsqueda en subespacios, se identifican diversas líneas de investigación que pueden fortalecer la detección de anomalías y la relevancia clínica de las alertas generadas.

Asignación de pesos diferenciados a subespacios críticos: En futuras implementaciones, sería de gran utilidad explorar la posibilidad de asignar diferentes pesos a los subespacios que incluyen variables fisiológicas de mayor relevancia clínica, como la presión arterial sistólica y diastólica, o la frecuencia cardíaca. Por ejemplo, los subespacios que reflejan cambios significativos en el estado hemodinámico del paciente pueden tener un impacto mayor en el cálculo del nivel de alerta global.

Para lograr esto, se propone ajustar la fórmula de criticidad para que cada subespacio contribuya de manera diferenciada al nivel de alerta general. Esto implicaría definir un conjunto de reglas clínicas que ponderen los subespacios según su importancia en el contexto clínico del paciente, permitiendo así una priorización más efectiva de las alertas.

Incorporación de información contextual adicional: Otra línea de trabajo consiste en integrar datos contextuales del paciente adicionales, como tratamientos médicos en curso y diagnósticos previos (historial de enfermedades cardiovasculares o respiratorias). Al incluir esta información, el modelo puede interpretar ciertas variaciones en los signos vitales como efectos esperados de un tratamiento, o bien, como señales de deterioro en presencia de condiciones preexistentes.

Para implementar este enfoque, se requiere diseñar una capa de preprocesamiento que recoja y normalice la información contextual. Además, es necesario ajustar la fórmula de criticidad para que los subespacios se ponderen según el perfil clínico individual de cada paciente. Así, la generación de alertas se vuelve más personalizada y contextualizada, lo que contribuye a reducir falsos positivos y aumentar el valor predictivo de cada notificación.

Evaluación en distintos grupos etarios dentro de la población pediátrica: Las respuestas fisiológicas varían considerablemente entre recién nacidos, lactantes y niños mayores. Por ello, es fundamental evaluar la utilidad del sistema en diferentes grupos etarios dentro del ámbito pediátrico. Se plantea realizar estudios comparativos que analicen la precisión y sensibilidad del modelo en subpoblaciones específicas, identificando posibles sesgos o desviaciones en la detección de anomalías según el rango de edad.

Análisis del impacto en la carga de trabajo y tiempos de respuesta del personal de salud: Finalmente, es esencial analizar cómo la implementación de este sistema influye en la carga de trabajo del personal médico y en los tiempos de respuesta ante eventos críticos. Se recomienda diseñar un protocolo de evaluación en un entorno real que mida métricas como el número de alertas diarias, el tiempo entre la generación de una alerta y la intervención clínica, y la percepción del

equipo de enfermería y médicos sobre la utilidad y facilidad de uso del tablero de control.

Para llevar a cabo este análisis, se sugiere establecer indicadores clave de rendimiento (KPI) que permitan cuantificar el impacto del sistema en la práctica clínica diaria. Esto no solo ayudará a validar la efectividad del modelo, sino que también proporcionará información valiosa para futuras mejoras y adaptaciones del sistema a las necesidades reales del personal de salud.

7.3. Conclusiones finales

En conclusión, el uso de modelos de búsqueda en subespacios para el análisis de datos fisiológicos ha demostrado ser una herramienta valiosa para la detección de anomalías en pacientes pediátricos. Este enfoque no solo mejora la precisión y sensibilidad en la identificación de patrones anómalos, sino que también proporciona una mayor interpretabilidad de las alertas generadas, facilitando la toma de decisiones clínicas informadas.

La capacidad de descomponer las señales fisiológicas en subespacios específicos permite una comprensión más detallada del impacto de cada signo vital en el estado del paciente, lo que resulta en alertas más relevantes y accionables. Además, la resiliencia del modelo ante la intermitencia de las señales y lecturas erróneas asegura su aplicabilidad en entornos clínicos reales, donde la variabilidad de los datos es una constante.

Este trabajo sienta las bases para futuras investigaciones en el campo de la monitorización de pacientes críticos, destacando la importancia de integrar enfoques innovadores que mejoren la atención y seguridad del paciente. Las líneas de trabajo propuestas abren nuevas oportunidades para optimizar aún más la detección de anomalías y la relevancia clínica de las alertas, contribuyendo así a una atención médica más efectiva y personalizada.

Bibliografía

- Adegboro, C. O., Choudhury, A., Asan, O., & Kelly, M. M. (2022). Artificial Intelligence to Improve Health Outcomes in the NICU and PICU: A Systematic Review. *Hospital Pediatrics*, 12(1), 93-110. <https://doi.org/10.1542/hpeds.2021-006094>
- Ahmad, S., Lavin, A., Purdy, S., & Agha, Z. (2017). Unsupervised real-time anomaly detection for streaming data [Online Real-Time Learning Strategies for Data Streams]. *Neurocomputing*, 262, 134-147. <https://doi.org/https://doi.org/10.1016/j.neucom.2017.04.070>
- Aiken, L. H., Clarke, S. P., Sloane, D. M., Sochalski, J., & Silber, J. H. (2002). Hospital Nurse Staffing and Patient Mortality, Nurse Burnout, and Job Dissatisfaction. *JAMA*, 288(16), 1987. <https://doi.org/10.1001/jama.288.16.1987>
- Arango, G. L., Peña, B., & Vega, Y. (2015). Relación de la asignación de personal de enfermería con indicadores de resultado de la calidad de la atención en unidades de cuidados intensivos adulto. *Aquichan*, 15(1), 90-104. <https://doi.org/10.5294/aqui.2015.15.1.9>
- Areia, C., King, E., Ede, J., Young, L., Tarassenko, L., Watkinson, P., & Vollam, S. (2021). Experiences of current vital signs monitoring practices and views of wearable monitoring: A qualitative study in patients and nurses. *Journal of Advanced Nursing*, 78(3), 810-822. <https://doi.org/10.1111/jan.15055>
- Ariste, R., Béjaoui, A., & Dauphin, A. (2019). Critical analysis of nurses' labour market effectiveness in Canada: The hidden aspects of the shortage. *The International Journal of Health Planning and Management*, 34(4), 1144-1154. <https://doi.org/10.1002/hpm.2772>
- Davenport, T., & Kalakota, R. (2019). The potential for artificial intelligence in healthcare. *Future Healthcare Journal*, 6(2), 94-98. <https://doi.org/https://doi.org/10.7861/futurehosp.6-2-94>
- Depasse, B., Pauwels, D., Somers, Y., & Vincent, J. L. (1998). A profile of European ICU nursing. *Intensive Care Medicine*, 24(9), 939-945. <https://doi.org/10.1007/s001340050693>

- Fernández, J. L. (2020). Aproximación y estabilización inicial del niño enfermo o accidentado. Triángulo de evaluación pediátrica. ABCDE. https://www.aeped.es/sites/default/files/documentos/02_tep_abcde.pdf
- Karalis, V. D. (2024). The Integration of Artificial Intelligence into Clinical Practice. *Applied Biosciences*, 3(1), 14-44. <https://doi.org/10.3390/applbiosci3010002>
- Lazo, W. L., & Andrade, C. L. (2020). *Manual de signos vitales en la población pediátrica*. Editorial Universidad de Los Lagos. <https://doi.org/10.32735/978-956-6043-18-8/2020>
- Ministerio de Salud de la provincia de Columbia Británica. (2024). Ratio Definitions for Hospital Sector - Province of British Columbia. <https://www2.gov.bc.ca/gov/content/health/practitioner-professional-resources/mnpr/mnpr-ratio-definitions>
- OECD. (2024). *Society at a Glance 2024: OECD Social Indicators*. <https://doi.org/10.1787/918d8db3-en>
- Otahal, M., Keeney, D., McDougall, D., et al. (2019). HTM.core implementation of Hierarchical Temporal Memory.
- Pieroni, M. (2023). *Machine Learning Modelling of Critical Care Patients in the Intensive Care Units* [Tesis doctoral, Liverpool John Moores University]. <https://doi.org/10.24377/LJMU.t.00019587>
- Rush, B., Celi, L. A., & Stone, D. J. (2018). Applying machine learning to continuously monitored physiological data. *Journal of Clinical Monitoring and Computing*, 33(5), 887-893. <https://doi.org/10.1007/s10877-018-0219-z>
- Vargas, G. E. (2023). MAD-VitalS: Solución de inteligencia artificial para el monitoreo y detección de anomalías en signos vitales de pacientes en UCIP en tiempo real. <https://hdl.handle.net/1992/68734>
- Varnosfaderani, S. M., & Forouzanfar, M. (2024). The Role of AI in Hospitals and Clinics: Transforming Healthcare in the 21st Century. *Bioengineering*, 11(4), 337. <https://doi.org/10.3390/bioengineering11040337>
- Zhang, T. Y., Zhong, M., Cheng, Y. Z., & Zhang, M. W. (2023). An interpretable machine learning model for real-time sepsis prediction based on basic physiological indicators. *European Review for Medical and Pharmacological Sciences*, 27(10), 4348-4356. https://doi.org/10.26355/eurrev_202305_32439